


智能评分系统特征与模型详解

（ FDT-AI 团队撰写 ）

智能评分系统（以下简称“华泰系统”或“系统”），以 FDT-AI 的 FDTScore 为模型基础，以交易团队的交易数据为数据源，根据华泰业务需要，对其交易员团队成员的交易能力（盈利能力、风控能力）进行分析及评分。

一、系统模块及数据流程

打分过程基于 spark 框架完成，具体步骤如下图所示：



1.1. 特征提取

数据预处理完成后，系统对每个交易员的交易记录做特征抽取。现有特征包括基础特征和行为特征两大类。特征抽取完成后，系统对特征做后处理，包括特征归一化，以及异常特征值过滤。

1.1.1. 基础特征

- TradeCount

交易次数。交易员在计算周期内总共的交易次数。

- TradeDays :

交易天数。计算交易员在计算周期内有交易活动（下单）的总天数。该特征分数越高，与该交易员的活跃度有正相关性。

- TradeLife :

交易寿命。计算交易员在计算周期内交易日的总数。

- ActiveRatio

活跃比率。交易天数与交易寿命的比值，该值越高，用户越活跃。

$$ActiveRatio = \frac{TradeDays}{TradeLife}$$

- AllTimePnl

总盈利。计算交易员在计算周期内的总收益。该特征分数越高，说明该交易员收益能力越强。总盈利会受到交易员可使用资金量的影响，但是一般认为操纵大资金对交易技能和风控能力有更高的要求。

$$AllTimePnl = \sum_{i=1}^N (SellPrice_i - BuyPrice_i) \times Quantity_i - Fee_i$$

N 为平仓单数

该特征分数越高，说明该交易员收益能力越强。总盈利会受到交易员可使用资金量的影响，但是一般认为操纵大资金对交易技能和风控能力有更高的要求。

- AvgDailyPnl

日均盈利。计算交易员在计算周期内的平均日盈利。

$$AvgDailyPnl = \frac{AllTimePnl}{TradeDays}$$

该特征分数越高，说明该交易员的盈利能力越强。

- AvgDailyVolume

日均交易量。交易员在计算周期内的平均日交易量。

$$AvgDailyVolume = \sum_{i=1}^N (SellPrice_i + BuyPrice_i) \times Quantity_i / TradeDays$$

N 为平仓单数

- AvgDuration

平均持仓时间。交易员在计算周期内的平均持仓时间。

- MinNegPnl

单笔最大损失。交易员在计算周期内的单笔最大损失。

注意“单笔”这里以两次连续空仓为单位进行定义，也就是连续加仓至全部平仓算作一次“单笔交易”。该特征值越高，说明该交易员导致大额损失的可能越高，需多控制仓位或者加强对黑天鹅事件的应对能力。

- AvgMinNegPnl

日均最大损失。交易员在其交易天数内，每日最大损失的均值。

- AvgTradeCount

日均交易次数。交易员在其交易天数内，每日平均交易次数。

- Streak

最长连盈天数。交易员在计算周期内，最长连续盈利的天数。该特征分数越高，该交易员的盈利能力越强，并与判断趋势能力有强的正相关性。

- ClosedPositionStreak

最长连盈次数。交易员在计算周期内的所有平仓记录中，最长连续盈利的次数。

- PnEfficiency

盈利效率。在每个已经平仓的交易里，计算盈利与交易资金总量比值。交易资金总量，包括买进卖出的量乘以其价格。

单个平仓交易的 $PnEffCP$ 计算为，

$$PnEffCP = Pnl / TotalTradeMoney$$

其中，

$$TotalTradeMoney = (SellPrice + BuyPrice) \times Quantity$$

对所有已经平仓的交易的 $PnEffCP$ 取均值，即为 $PnEfficiency$ 。系统在给交易员打分时使用特征原始值。而在显示该特征时将特征值取倒数，表示每个单位的盈利需要的资金量，值越小，说明该交易员利用资金的效率越高。

- DailyPnEff

日均盈利效率。交易员在所有交易日中，平均每个交易日的盈利效率(PnL Efficiency)，即所有交易日资金使用效率的均值。该特征分数越高，该交易员的盈利能力越强。

- EffSharpeRatio

盈利效率夏普比率。以日盈利效率为样本值计算得到的 sharpe-ratio。

$$PNLEFF = \{pnleff_i = (\sum_{j=1}^{N_i} pnl_j) / (\sum_{j=1}^{N_i} volume_j)\}, i \text{ 为某个交易日, } N_i \text{ 为第 } i \text{ 个交易日的平仓单数}$$

$$EFFSharpeRatio = \frac{mean(PNLEFF)}{std(PNLEFF)}$$

- EffSortinoRatio

盈利效率索提诺比率。以日盈利效率为样本值计算得到的 sortino-ratio。

$$PNLEFF = \{pnleff_i = (\sum_{j=1}^{N_i} pnl_j) / (\sum_{j=1}^{N_i} volume_j)\}, i \text{ 为某个交易日, } N_i \text{ 为第 } i \text{ 个交易日的平仓单数}$$

$$EFFSortinoRatio = \frac{mean(PNLEFF)}{std_neg(PNLEFF)}$$

其中， $std_neg(*)$ 计算的是样本为负时的标准差。

- EffVar

盈利效率 VaR。以日盈利效率为样本值计算得到的风险价值（Value at Risk）。

$$PNLEFF = \{pnleff_i = (\sum_{j=1}^{N_i} pnl_j) / (\sum_{j=1}^{N_i} volume_j)\}, i \text{ 为某个交易日, } N_i \text{ 为第 } i \text{ 个交易日的平仓单数}$$

$$EFFVaR = VaR(PNLEFF)$$

其中 VaR 阈值为 5%。特征分数越高，该交易员的风控水平越高。

- OpenPositionVolume

持仓量。交易员尚未平仓量。

- StdNegEff

损失效率波动。以日盈利效率为样本值的数据中，收益为负的样本的标准差值。该特征指明某个交易员的风控水平是否稳定，是否有较一致并可控制的亏损预期；该特征分数越大，说明交易员越有可能带来超过预期的亏损。

$$NEGEFF = \{eff_i = (\sum_{j=1}^{N_i} pnl_j) / (\sum_{j=1}^{N_i} volume_j), eff_i < 0\}, i \text{ 为某个交易日, } N_i \text{ 为第 } i \text{ 个交易日的平仓单数}$$

$$StdNegEff = STD(NEGEFF)$$

该特征指明某个交易员的风控水平是否稳定，是否有较一致并可控制的亏损预期；该特征分数越小，说明交易员越有可能带来超过预期的亏损。

- StdQuantity

交易数量波动。交易数量在计算周期内的标准差。

- StdVolume

交易量波动。交易金额在计算周期内的标准差。

- WinRatio

盈利比率。在已平仓的交易中，交易员盈利的次数与总交易次数的比值。

- WinningDayRatio

盈利天数比率。在所有的交易天数中，交易员盈利的天数占总交易天数的比值。该特征分数越大，说明交易员的发挥越稳定。超过 50%说明盈利为主，并且心态稳定。

- AvgDailyHoldNum

日均持仓股票支数。计算用户每日持仓股票支数的平均值。

- AvgMaxOpenPositionRatio

日均最大持仓量与资产比率。计算用户每日多个持仓中，最大持仓的股票价值与资产总量的比值的平均值。

- AvgOverNightOpenPosition

平均过夜持仓量与资产比率。计算用户每日过夜持仓的股票价值与资产总量比值的平均值。

- BiggestLoss

最大损失。用户所有平仓记录中的最大亏损金额。

- BiggestLossRatio

最大损失比率。用户所有平仓记录中最大损失占当天净资产的比率。

- BiggestWin

最大盈利。用户所有平仓记录中最大的盈利金额。

- BiggestWinRatio

最大盈利比率。用户所有平仓记录中最大的盈利占当天净资产的比率。

- DivConsistency

持仓股票数量稳定性。用户每日持仓股票数量的标准差。

- MaxDrawDown

最大回撤。用户所有回撤中最大回撤。

- MaxDrawdownSpeed

最大回撤速率。用户所有回撤中最大回撤速率。通常用户的净资产曲线会有很多回撤，本特征计算的是回撤速率最大的一次回撤。

- OpenPositionsVolume

持仓金额。用户所有持仓股票的总金额。

- SharpeRatio

夏普比率。计算用户的夏普比率值。

- SortinoRatio

索提诺比率。计算用户的索提诺比率值。

- TimedMaxDrawDown

最大回撤时间。计算用户在其最大回撤的过程中使用的时间。

- TotalSymbols

历史持仓股票总支数。用户交易生命周期中总共购买过的股票支数。如果用户多次购买同一支股票，记为一支股票。

- UnitPrice

资产净值。

- ValueAtRisk

风险价值，即 VaR。风险收益比。通过分析用户交易时的潜在风险与最终盈利的比值，来分析用户的止盈时机是否合适。

- WinRatio

平仓记录盈利比率。用户所有股票的平仓记录中，盈利笔数占总平仓笔数的比率。

- WinningDayRatio

盈利天数比率。用户所有交易天数中，盈利天数占总交易天数的比率。

1.1.2. 行为特征

- PositionEfficiency

仓位效率。对该交易员所有的交易，计算其收益与行情波动的比率的平均值。该特征指明该交易员把握行情波动的能力，该特征分数越大，说明交易员可以越好的掌握建仓和平仓的时间，即交易员抓波动的能力。

对于已经平仓的交易，特征计算为，

$$PositionEfficiency = \sum_{i=1}^N \frac{SellPrice_i - BuyPrice_i}{HighPrice - LowPrice} / N$$

其中，N 为平仓单数，HighPrice 和 LowPrice 是从买到卖时间区间之内行情的高点和低点。

- PotentialRisk

仓位潜在风险。该特征根据该交易员在计算周期内所有的仓位记录，计算其开仓、平仓之间，所交易之标的市场价格向其仓位逆向运动的平均程度。该特征反映交易员是否经常进行俗称“左手交易”的操作，即系统性的承担浮亏。

该特征始终为负值，分数越高，说明交易员承担的潜在风险越低，反之，该特征分数越低，说明交易员承受的潜在风险越大，如果遇到市场波动加大或者系统风控水平调整，会有机会导致更多的亏损交易。

$$PotentialRisk = \left(\sum_{i=1}^{N1} \frac{LowPrice - BuyPrice_i - Fee_i}{Quantity_i \times BuyPrice_i} + \sum_{i=1}^{N2} \frac{SellPrice_i - HighPrice - Fee_i}{Quantity_i \times SellPrice_i} \right) / (N1 + N2)$$

其中，N1 为建仓买单数量，N2 为建仓卖单数量，HighPrice 和 LowPrice 是从买到卖时间区间之内行情的高点和低点。

该特征反映交易员是否经常进行俗称“左手交易”的操作，即系统性的承担浮亏。该特征分数越低，说明交易员承受的潜在风险越大，如果遇到市场波动加大或者系统风控水平调整，会有机会导致更多的亏损交易。

- RiskOverPnl

风险收益比。该特征计算交易员每笔交易中所承担的最大潜在风险与其最终收益的比率的平均值。该特征反映交易员取得每单位收益需要承担的平均潜在风险水平。

该特征始终为负值，分数越高，说明该交易员在取得同样收益的情况下承担的风险水平越低，或者同样风险水平下取得收益的能力越高。

$$RiskOverPnl = \left(\sum_{i=1}^{N1} \frac{LowPrice - BuyPrice_i - Fee_i}{(SellPrice_i - BuyPrice_i) \times Quantity_i - Fee_i} + \sum_{i=1}^{N2} \frac{SellPrice_i - HighPrice - Fee_i}{(SellPrice_i - BuyPrice_i) \times Quantity_i - Fee_i} \right) / (N1 + N2)$$

其中，N1 为建仓盈利买单数量，N2 为建仓盈利卖单数量，HighPrice 和 LowPrice 是从买到卖时间区间之内行情的高点和低点。

该特征反映交易员取得每单位收益需要承担的平均潜在风险水平。该特征分数越高，说明该交易员在同样风险水平下取得收益的能力越高。

- Diversity

持仓多样性。通过分析用户持仓的分布情况，来描述用户仓位分布是否多样，是否有对冲性。

1.1.3. 心里特征

- Disposition

错位效应。通过分析用户平仓时止盈止损的情况，来描述用户在面对仓位盈亏时的心理偏差。

- HerdEffect

羊群效应。通过分析用户交易的时间点，来分析用户下单交易时是否容易受大盘影响，还是保持相对独立的判断。

1.1.4. 特征值归一化

特征值归一化主要分三步：

1) 选择基准交易员 (baseline users)，即通过条件过滤得到 FDT-AI 全量数据的一部分 (10%左右) 交易员，这些交易员通常具有较为稳定的输出。

2) 对基准交易员进行排序并+++++++归一化，将这些基准交易员的每个特征值进行排序，并按比例映射到 [0,100] 的区间。

3) 对其他交易员按照基准交易员做 pivoting。对于非基准交易员，系统对其特征值在基准交易员排序的基础上进行匹配查找，并将匹配得到的最近邻得分作为该交易员的对应得分。

$$\hat{x} = \arg \min_{x \in X} |f - f_{baseline}(x)|$$
$$\hat{f}_{norm} = f_{norm}(\hat{x})$$

其中， $f_{baseline}(x)$ 是基准交易员的原始特征值， f 是非基准交易员的原始特征值， $f_{norm}(x)$ 是基准交易员的归一化特征值， $\hat{f}_{norm}$ 为非基准交易员的归一化值。

小数据量在归一化时通常有不稳定的输出。使用与基准交易员匹配的方法可以解决系统在归一化中的小数据量问题。即通过输入 FDT-AI 基准交易员稳定的先验值，即使新系统在初始化时数据量很小，也能产生稳定的输出。


在进一步研究华泰交易员的实际数据分布之后，会逐步调整和优化归一化方案，使之更为符合实际需求。

对于异常值，如果系统在实际运行中有特定的需求，如对特殊交易员或者某些特征值有限制，系统可提供方案，对异常值进行过滤。

1.2. 评分模型及算法

1.2.1. 多模型融合架构：贝叶斯模型叠加 (Bayesian Model Stacking)

为了提高模型泛化能力和数据利用效率，模型架构分为两层，简单模型层和模型叠加层 (Model Stacking)，如下图所示。



简单模型层分为两个部分，每个部分包含若干个子模型，这些模型使用清洗好的数据和特征，由 FDT AI 数据和华泰数据分别构建得到。模型叠加层主要使用贝叶斯模型叠加 (Bayesian Model Stacking) 方法。使用贝叶斯模型叠加的框架可以解决系统的冷启动和数据稀疏性问题，在模型从 FDT-AI 的用户群迁移到华泰用户群的初始阶段，新用户群的数据量可能非常少，使用本框架的方法，可以有效地利用 FDT-AI 的数据和模型方面的优势及先验知识，使得对新用户的打分在初始阶段可以依赖先验概率模型得到较为稳定的输出。因此可增加模型在不同数据集间的适应性，实现模型和系统的平稳过渡和迁移，提高模型的预测能力。

模型叠加层需要解决的问题是每个子模型在最终模型中的权重。假设系统总共从简单模型层得到 p 个子模型集合 $M = \{M_1, \dots, M_p\}$ ，将这 p 个模型的输出作为模型叠加层的输入，得到如下函数形式：

$$f(x) = \sum_{k=1}^p \beta_k M_k(x)$$

模型叠加层的目标是求解 $\beta = (b_1, \dots, b_p)^T$ ，使得最终输出模型是子模型集合的优化。算法求解过程分两步：1) 根据贝叶斯模型平均 (Bayesian Model Averaging)，引入模型先验，并对后验分布进行采样，从而得到参数的近似解。2) 通过广义弹性网 (Generalized Elastic Net) 回归进行模型选择，并确定模型参数。

1) 贝叶斯模型平均 (BMA)

假设系统有 n 个样本， p 个子模型 $M = \{M_1, \dots, M_p\}$ 的输出为 $n \times p$ 的矩阵 X 。回归模型定义为：

$$Y = X\beta + \epsilon$$

其中， $X = [x_1, \dots, x_n]^T \in R^{n \times p}$ ， $Y = [y_1, \dots, y_n]^T \in R^n$ ，误差项 ϵ 符合高斯随机分布 $N(0, \sigma^2)$ 。

贝叶斯平均模型设计如下：

$$\begin{aligned} (y_i^* | x_i, \beta, \sigma^2) &\sim N(x_i \beta, n\sigma^2), \quad i = 1, \dots, n \\ (\beta_k | c_k, \tau_k^2) &\sim N(\beta_{0,k}, c_k \tau_k^2), \quad k = 1, \dots, p \\ (c_k | v_0, w) &\sim (1-w) \delta_{v_0}(\cdot) + w \delta_1(\cdot) \\ (\tau_k^2 | a_1, a_2) &\sim \psi_{a_1, a_2}(\cdot) \\ w &\sim \text{Uniform}(0, 1) \\ \sigma^2 &\sim \psi_{b_1, b_2}(\cdot) \end{aligned}$$

其中，

$$\psi_{a_1, a_2}(\sigma) = (a_2^{a_1} / (a_1 - 1)!) \sigma^{-(a_1+1)} \exp(-a_2/\sigma), \quad \sigma > 0.$$

$$y_i^* = \hat{\sigma}_n^{-1} n^{1/2} y_i, \quad \hat{\sigma}_n^2 = \|Y - X\hat{\beta}_n^0\|^2 / (n-p), \quad \hat{\beta}_n^0 = (X^T X)^{-1} X^T Y \text{ 是一般线性回归系数。}$$

对于使用 FDT-AI 数据学习到的子模型，可设定其先验的参数 $\beta_0 = 0$ 。对于使用华泰数据学习到的子模型，可将先验参数设定为由 FDT-AI 数据求得得到的 β_0 。

使用马尔可夫链蒙特卡洛 (MCMC) 对后验分布进行采样，可求得叠加系数 β 的解，记为

β_{bma} 。

1.2.2. 子模型一：启发式线性模型

根据前期的业务讨论基础，同时为了初期上线与磨合的透明与可控性，在前期实盘交易团队初期调整的基础上，系统提供的其中一个子模型为启发式线性模型。

该线性模型，是 FDT 科学家以 FDT 实盘交易员的交易记录得到的特征的基础上，根据专家经验所设置的启发式打分系统。该系统根据为交易员的风控能力，盈利能力，一致性和活跃度这四个维度上分别打分，每个维度使用特征库中的若干个特征，以不同权重加以线性组合而得到。系统在第一阶段所使用的权重系数，是 FDT 工程师在华泰自有交易员的数据中经过实验，并且实验结果得到华泰业务部门认可的值。

1) 盈利能力

交易员的盈利能力评分，目前使用到的特征值有，总盈利 (AllTimePnl)，日均盈利 (AvgDailyPnl)，仓位效率 (PositionEfficiency)，盈利天数比率 (WinningDayRatio)，盈利效率 (PnlEfficiency)，日均盈利效率 (DailyPnlEff)，最长连盈天数 (Streak)，盈利效率夏普比率 (EffSharpeRatio)。

假设以上特征值为 $X = \{x_0, x_1, \dots, x_{n-1}\}$ ，其所对应的权重值为 $W = \{w_0, w_1, \dots, w_{n-1}\}$ ，盈利能力的分值为其特征和所对应权重的线性加权和：

$$y_{profit_1} = \sum_{i=0}^{n-1} w_i x_i$$

2) 风控能力

交易员的风控能力评分，目前使用到的特征值有，单笔最大损失 (MinNegPnl)，日均最大损失 (AvgMinNegPnl)，损失效率波动 (StdNegEff)，仓位潜在风险 (PotentialRisk)，风险收益比 (RiskOverPnl)，盈利效率 VaR (EffVar)。

与盈利能力的计算方式相似，风控能力的分值计算为以上特征及其所对应权重的线性加权和：

$$y_{riskCtrl_1} = \sum_{i=0}^{n-1} w_i x_i$$

3) 一致性

交易员的一致性评分，目前使用到的特征有，盈利效率索提诺比率 (EffSortinoRatio)，损失效率波动 (StdNegEff)，交易数量波动 (StdQuantity)，交易量波动 (StdVolume)。

活跃度的分值为以上特征及其所对应权重的线性加权和：

$$y_{consistency_1} = \sum_{i=0}^{n-1} w_i x_i$$

4) 活跃度

交易员的活跃度评分，目前使用到的特征有，交易寿命 (TradeLife)，交易天数 (TradeDays)，交易次数 (TradeCount)。

活跃度的分值为以上特征及其所对应权重的线性加权和：

$$y_{activity_1} = \sum_{i=0}^{n-1} w_i x_i$$

1.2.3. 子模型二：线性回归模型

除启发式打分模型外，系统目前为盈利能力，风控能力和一致性这 3 个维度各提供 3 个通过训练得到的模型，即共 9 个训练模型。训练数据集使用交易员 3 个月的操作数据，目标数据集取交易员的训练数据往后截取 1 个月的数据，即训练数据集和目标数据集为 (3+1) 个月的模式。

盈利能力，风控能力和一致性的目标的选取，使用目标数据集计算得到的特征，经过线性组合得到。计算方式参考上节启发式线性模型所述。

线性回归模型输入的特征从训练数据中抽取得到。使用的特征包括：交易次数 (TradeCount)，交易天数 (TradeDays)，交易寿命 (TradeLife)，活跃比率 (ActiveRatio)，总盈利 (AllTimePnl)，日均盈利 (AvgDailyPnl)，日均交易量 (AvgDailyVolume)，平均持仓时间

(AvgDuration), 单笔最大损失 (MinNegPnl), 日均最大损失 (AvgMinNegPnl), 日均交易次数 (AvgTradeCount), 最长连盈天数 (Streak), 最长连盈次数 (ClosedPositionStreak), 盈利效率 (PnlEfficiency), 日均盈利效率 (DailyPnlEff), 盈利效率夏普比率 (EffSharpeRatio), 盈利效率索提诺比率 (EffSortinoRatio), 盈利效率 VaR (EffVar), 损失效率波动 (StdNegEff), 交易数量波动 (StdQuantity), 交易量波动 (StdVolume), 盈利比率 (WinRatio), 盈利天数比率 (WinningDayRatio), 仓位效率 (PositionEfficiency), 仓位潜在风险 (PotentialRisk), 风险收益比 (RiskOverPnl)。

线性回归模型的一般形式为：

$$y = X\beta + \varepsilon,$$

其中， y 为目标， X 为特征向量。

1.2.4. 子模型三：梯度提升决策树回归模型

梯度提升决策树回归模型的训练数据集，拟合目标数据集以及特征集的选取，跟子模型二中的线性回归模型相同。

梯度提升决策树算法的核心思想是使用每次迭代的过程中损失函数的负梯度来拟合一个回归树：

$$r_{im} = - [\partial L(y_i, F(x_i)) / \partial F(x_i)]_{F(x)=F_{m-1}(x)}$$

其中， $L(y, F(x))$ 为损失函数， y 为拟合目标， $F(x)$ 为拟合函数， r_{im} 为残差， m 为迭代次数。

1.2.5. 子模型四：随机森林回归模型

随机森林回归模型的训练数据集，拟合目标数据集以及特征集的选取，跟子模型二中的线性回归模型相同。

随机森林通过自助法（bootstrap）重采样技术，从原始训练样本集 N 中有放回地重复随机抽取 n 个样本生成新的训练样本集合训练决策树，生成 m 棵决策树的组成随机森林。随机森林由其算法本身的特性，具有很好的抗噪能力，不易过拟合，能处理高维度的数据，并且性能稳定。

1.2.6. FDTScore 计算

交易员总体的盈利能力，风控能力，一致性由以上四个子模型在训练集上的输出，通过贝叶斯模型平均，得到各个子模型在以上三个维度的能力中的权重值。

交易员的 FDTScore 总分，将计算为盈利能力，风控能力，一致性和活跃度的这四个维度再以不同权重的线性组合得到。交易员的 FDTScore 总分计算为：

$$FDTScore = w_0 y_{profit} + w_1 y_{riskCtrl} + w_2 y_{consistency} + w_3 y_{activity}$$